ICS 35.240
CCS L 70

中华人民共和国国家标准化指导性技术文件

GB/Z 253—2026

人工智能　检索增强生成通用技术要求

Artificial intelligence—General technical requirements of retrieval-augmented generation

2026-08-27 发布

国家市场监督管理总局
国家标准化管理委员会　发布

目　　次

前言 …… Ⅲ
1　范围 …… 1
2　规范性引用文件 …… 1
3　术语和定义 …… 1
4　缩略语 …… 1
5　通用技术框架 …… 1
6　知识库要求 …… 2
6.1　数据接入 …… 2
6.2　知识获取 …… 2
6.3　知识切分 …… 3
6.4　知识增强 …… 3
6.5　知识索引 …… 4
7　检索增强生成要求 …… 5
7.1　查询理解 …… 5
7.2　知识检索 …… 5
7.3　语义排序 …… 6
7.4　答案生成 …… 6

前　言

本文件为规范类指导性技术文件。

本文件按照GB/T 1.1—2020《标准化工作导则　第1部分：标准化文件的结构和起草规则》的规定起草。

请注意本文件的某些内容可能涉及专利。本文件的发布机构不承担识别专利的责任。

本文件由全国信息技术标准化技术委员会(SAC/TC 28)提出并归口。

本文件起草单位：中国电子技术标准化研究院、北京百度网讯科技有限公司、蚂蚁科技集团股份有限公司、百度云智(北京)科技有限公司、中国石油天然气股份有限公司塔里木油田分公司、上海文鳐信息科技有限公司、中移(杭州)信息技术有限公司、中移(苏州)软件技术有限公司、浪潮软件科技有限公司、浪潮通信信息系统有限公司、厦门渊亭信息科技有限公司、中电信数智科技有限公司、浪潮电子信息产业股份有限公司、中移雄安信息通信科技有限公司、中国电子技术标准化研究院华东分院、浙江大华技术股份有限公司、中移互联网有限公司、上海商汤智能科技有限公司、深信服科技股份有限公司、海信集团控股股份有限公司、江苏赛西科技发展有限公司、中移九天人工智能科技(北京)有限公司、中国移动通信集团有限公司、中兴通讯股份有限公司、上海翰纬信息科技有限公司、北京软件产品质量检测检验中心有限公司、深圳前海微众银行股份有限公司、南京理工大学、北京神舟航天软件技术股份有限公司、国网天津市电力公司电缆分公司、江苏金服数字集团人工智能科技有限公司、中国南方电网有限责任公司超高压输电公司、宁波宁帆信息科技有限公司、杭州捷配链数字科技有限公司。

本文件主要起草人：董建、张彬琳、李景秋、刘增志、彭晋、孙曦、徐洋、马珊珊、王金山、袁骁、仲凯韬、潘宏博、付涛、李旭东、王珂琛、李照川、梁秉豪、肖红梅、洪万福、朱成忠、陈利明、袁硕之、邸贺亮、郑庆国、严小格、费玥、陈庆洋、韩鹏飞、孔维生、茹宏格、肖夏阳、王和俊、徐金涛、王红伟、田羽慧、张建、董月文、秦日臻、曹汐、张宏伟、史磊、孔昊、高玉翔、戚湧、于连坤、密伟、潘风文、管俊明、李学武、石凡、李君、王宁、彭黔平、杨越。

人工智能　检索增强生成通用技术要求

1　范围

本文件确立了检索增强生成的通用技术框架，规定了检索增强生成、知识库等功能要求。

本文件适用于指导检索增强生成系统的设计和开发。

2　规范性引用文件

本文件没有规范性引用文件。

3　术语和定义

下列术语和定义适用于本文件。

3.1

检索增强生成　retrieval-augmented generation

从预构建的知识库或数据源中检索相关信息，在特定任务上增强生成式人工智能模型的方法。

3.2

检索增强生成系统　retrieval-augmented generation system

基于检索增强生成技术构建的人工智能系统。

4　缩略语

下列缩略语适用于本文件。

API：应用程序编程接口（Application Programming Interface）

FTP：文件传输协议（File Transfer Protocol）

GIF：图形交换格式（Graphics Interchange Format）

MP3：动态图像专家组第1版标准　音频层第三级（MPEG-1 Audio Layer 3）

MP4：动态图像专家组第4版标准　第14部分（MPEG-4 Part 14）

RAG：检索增强生成（Retrieval-Augmented Generation）

5　通用技术框架

RAG通用技术框架见图1，框架主要包括：

a）　检索增强生成：通过查询理解、知识检索、语义排序、答案生成等过程，生成与查询问题相关的答案；

b）　知识库：接入不同来源和异构的数据，进行知识获取和知识切分，抽取实体信息、生成对应的问题、摘要等，来构建查询问题相关的知识库，以便通过向量索引、全文索引等更高效的方式被索引到。

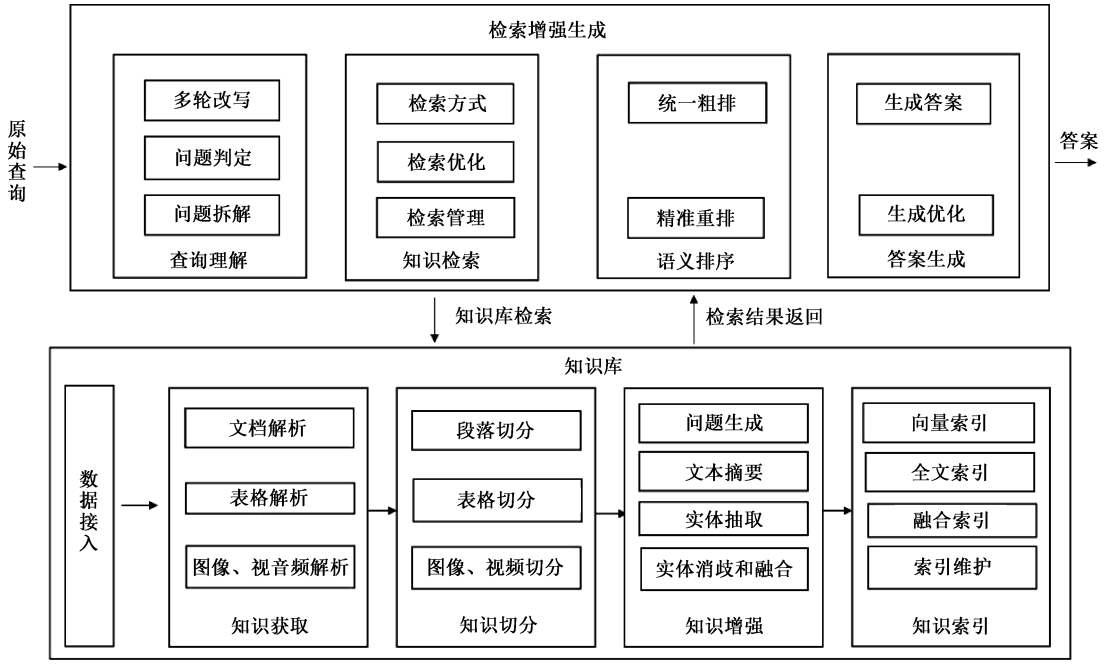


图 1 通用技术框架

6 知识库要求

6.1 数据接入

数据接入要求如下：

a) 应支持多种来源数据接入，如数据库、数据仓库、存储型数据源、本地或云端存储系统等；

b) 应支持结构化数据、半结构化数据和非结构化数据接入；

c) 宜支持周期性接入数据，如按照设置的时间间隔定期接入数据等；

d) 宜支持通过数据连接器获取其他系统数据；

e) 宜支持对数据的查询、更新和管理；

f) 宜支持数据质量保障机制，如格式校验、重复检测、缺失值识别与处理等；

g) 宜支持多种数据接入方式，如文件接入、FTP 接入、API 接入等；

h) 宜支持数据接入异常处理机制，如失败重试、错误日志记录与告警通知。

6.2 知识获取

6.2.1 文档解析

文档解析要求如下：

a) 应支持将不同格式的文档内容转换并存储为统一的文本或结构化数据；

b) 应支持文档数据的切分、分类和标记等数据结构化处理；

c) 应支持文档版面分析和逻辑结构识别，包括识别并标记标题(各级)、段落、列表(有序/无序/自定义)、表格、图片、公式、代码块等不同语义区域及其层级关系和属性；

d) 宜支持文档内容的语义标注与知识抽取，如命名实体识别、事件识别、关系抽取等；

e) 宜支持多语种文档的统一解析与翻译。

6.2.2 表格解析

表格解析要求如下：

a） 应支持将不同表格文件数据转化为统一的结构化数据并存储；

b） 宜支持待索引列数据配置。

6.2.3 图像、视音频解析

图像、视音频解析要求如下：

a） 应支持将不同格式的输入数据解析并存储为统一的图像、视音频格式，如 MP3、MP4、GIF 等；

b） 应支持图像描述生成，用自然语言描述图像的主要内容、场景和氛围；

c） 宜支持文档中图像、视频，或图像视频文件的导入；

d） 宜支持图像中文本和特征提取；

e） 宜支持视频内容摘要生成；

f） 宜支持视频内容的目标识别，如物体识别、场景识别和文本提取；

g） 宜支持音频通道的内容解析，如语音识别、声纹识别、情绪识别等。

6.3 知识切分

6.3.1 段落切分

段落切分要求如下：

a） 应提供多种文本段落切分规则，如按照指定字符、字符数量、语义边界等切分规则；

b） 应提供切分结果与原始文档的结构映射，如原文件标识、页面编号、段落标题、文档索引位置、知识图谱节点等；

c） 应支持已切片信息的补全与拓展；

d） 宜支持切分规则的自定义和扩展。

6.3.2 表格切分

表格切分要求如下：

a） 应支持对表格数据的多种切分方式，如按照行、列、单元格等切分方式；

b） 宜支持表格元信息与表格切分的关联，如表格标题、脚注、编号、原始文档的上下文描述。

6.3.3 图像、视频切分

图像、视频分片要求如下：

a） 应支持文档中图像、视频数据的切分数据生成；

b） 应支持图像、视频数据描述信息的语义生成；

c） 宜支持图像、视频文件的切片数据生成。

6.4 知识增强

6.4.1 问题生成

问题生成要求如下：

a） 应支持针对知识点生成潜在检索问题；

b） 宜支持结合上下文语境生成多样化问题；

c） 宜支持对生成问题的合理性进行过滤，避免重复或无意义问题。

6.4.2 文本摘要

文本摘要要求如下：

a） 应支持长文本核心要素提炼，如核心观点、事件、实体及属性等；

b） 应支持结构化和非结构化摘要生成；

c） 宜支持多粒度摘要生成。

6.4.3 实体抽取

实体抽取要求如下：

a） 应支持文本结构化信息的自动化提取，如实体、属性、关系等；

b） 宜支持切片数据挖掘和信息泛化能力，如通过聚类分析发现隐藏的主题，或通过知识图谱构建发现实体之间的关系；

c） 宜支持实体间显式和隐式关联网络构建，如时序、因果、逻辑链接；

d） 宜支持图片、视频内容描述信息的生成；

e） 宜支持标注实体的类型和置信度。

6.4.4 实体消歧和融合

实体消歧和融合要求如下：

a） 应支持跨文档或跨上下文的实体对齐，消除同名实体的歧义；

b） 宜支持通过上下文关联分析或知识图谱嵌入技术实现语义消歧；

c） 宜支持合并冲突属性并补充缺失信息，形成统一的实体表达。

6.5 知识索引

6.5.1 向量索引

向量索引要求如下：

a） 应支持知识的向量数据库存储；

b） 应支持查询和知识的向量化表示；

c） 应支持向量索引结构的构建，如哈希索引、树结构以及图结构；

d） 应支持基于近似最近邻搜索算法进行向量匹配；

e） 宜支持向量检索工具或框架接入；

f） 宜支持多模态向量索引构建。

6.5.2 全文索引

全文索引要求如下：

a） 应支持倒排索引的构建与维护；

b） 应支持基于知识点的层次化检索。

6.5.3 融合索引

应支持向量索引与全文索引的联合查询。

6.5.4 索引维护

索引维护要求如下：

a） 应支持动态更新，实时或定时同步新增、删除、修改的数据；
b） 宜支持版本控制，如版本回溯。

7 检索增强生成要求

7.1 查询理解

7.1.1 多轮改写

多轮改写要求如下：
a） 应支持用户查询信息的优化，如语法规范化、语义增强、关键词扩展等；
b） 应支持用户查询信息个性化调整，如上下文语境重构、用户意图保持、语义一致性调整等；
c） 宜支持根据对话上下文的问题改写。

7.1.2 问题判定

问题判定要求如下：
a） 应支持对问题的分类，如问题复杂度的判定与分类，查询的多轮和复合；
b） 宜支持根据问题类型或意图，动态调整后续处理流程，如对敏感或超出范围的意图进行识别、引导或拒识。

7.1.3 问题拆解

问题拆解应支持将复杂问题拆解成多个简单问题。

7.2 知识检索

7.2.1 检索方式

检索方式要求如下：
a） 应支持至少一种全文检索方式，包括关键词检索、实体检索、事件检索等；
b） 应支持语义检索，包括基于向量空间模型的语义检索，向量空间模型支持高维向量表示；
c） 应支持混合检索，如全文检索和语义检索的组合检索策略；
d） 宜支持多模态检索，如对图片、音频、视频文件的理解和内容检索。

7.2.2 检索优化

检索优化要求如下：
a） 应支持检索筛选，如通过标签、文件标识等元信息配置检索范围；
b） 应支持语义检索优化，如文本语义向量模型优化、跨模态语义向量模型优化等；
c） 应支持全文检索优化，如通过构建关键词表、构建符合查询范围的知识点来提升全文检索效果；
d） 宜支持检索结果的去重与质量评估；
e） 宜支持基于知识图谱的检索。

7.2.3 检索管理

检索管理要求如下：
a） 应支持基于角色或权限的文档和知识点访问控制；
b） 宜支持敏感信息脱敏处理，例如掩码关键字段或动态隐藏内容；

c） 宜支持集成安全合规检查模块。

7.3 语义排序

7.3.1 统一粗排

统一粗排要求如下：

a） 应支持查询内容批量召回切片和排序，如基于时间、来源、相关性得分等排序；

b） 宜支持排序权重配置。

7.3.2 精准重排

精准重排要求如下：

a） 应支持基于查询内容和切片内容语义进行精准排序；

b） 应支持深度语义匹配；

c） 宜支持高效的级联排序或多阶段排序架构，在保证最终排序质量的前提下，平衡计算开销和响应延迟。

7.4 答案生成

7.4.1 生成答案

生成答案要求如下：

a） 应支持生成式模型接入；

b） 应支持知识、记忆等上下文内容接入；

c） 应支持将用户查询信息作为模型输入；

d） 应支持将文档切片信息作为模型输入；

e） 应支持将用户提示词作为模型输入；

f） 应支持生成内容合规性检查；

g） 宜支持切片中多模态数据作为模型输入；

h） 宜支持对模型输入的组合方式进行优化。

7.4.2 生成优化

生成优化要求如下：

a） 应支持生成性能优化，如提升吞吐率、降低单个词元生成时延等；

b） 宜支持生成结果的可信度评估，如提供置信度分数。